Infinity 365 Conference

Microsoft Foundry & AI Studio

audiocodes AvePoint COSMO CONSULT CUBIC SOLUTIONS EXPERTS INSIDE

neat. ppedv Rencore smartpoint bechtlegroup

Michael Plettner

https://bio.link/plemich

Infinity 365 Conference

IN2SUCCESS

TALK Microsoft 365
DER PODCAST FÜR MICROSOFT 365

Microsoft Teams
User Group Germany

Decode AI

Global AI Chapter
Global AI Munich
Munich, Germany

global AI community

audiocodes AvePoint COSMO CONSULT CUBIC SOLUTIONS EXPERTS INSIDE neat. ppedv Rencore smartpoint bechtlegroup

Wann reicht der managed Weg nicht?

- **Copilot Studio**
  - Citizen Developer, kein Code
  - Standard-RAG auf M365-Daten
  - Out-of-the-box-Konnektoren
  - Schneller Rollout
- **Microsoft Foundry**
  - Custom RAG, eigene Infra
  - Multi-Modell, volles Tracing
  - Komplexe Tool-Orchestrierung
  - Kosten- & Infra-Kontrolle

Teil 1 · Die Begriffe

RAG · Chunking & Embeddings · Agent & Tool-Calls · Tracing

RAG – erst nachschlagen, dann antworten

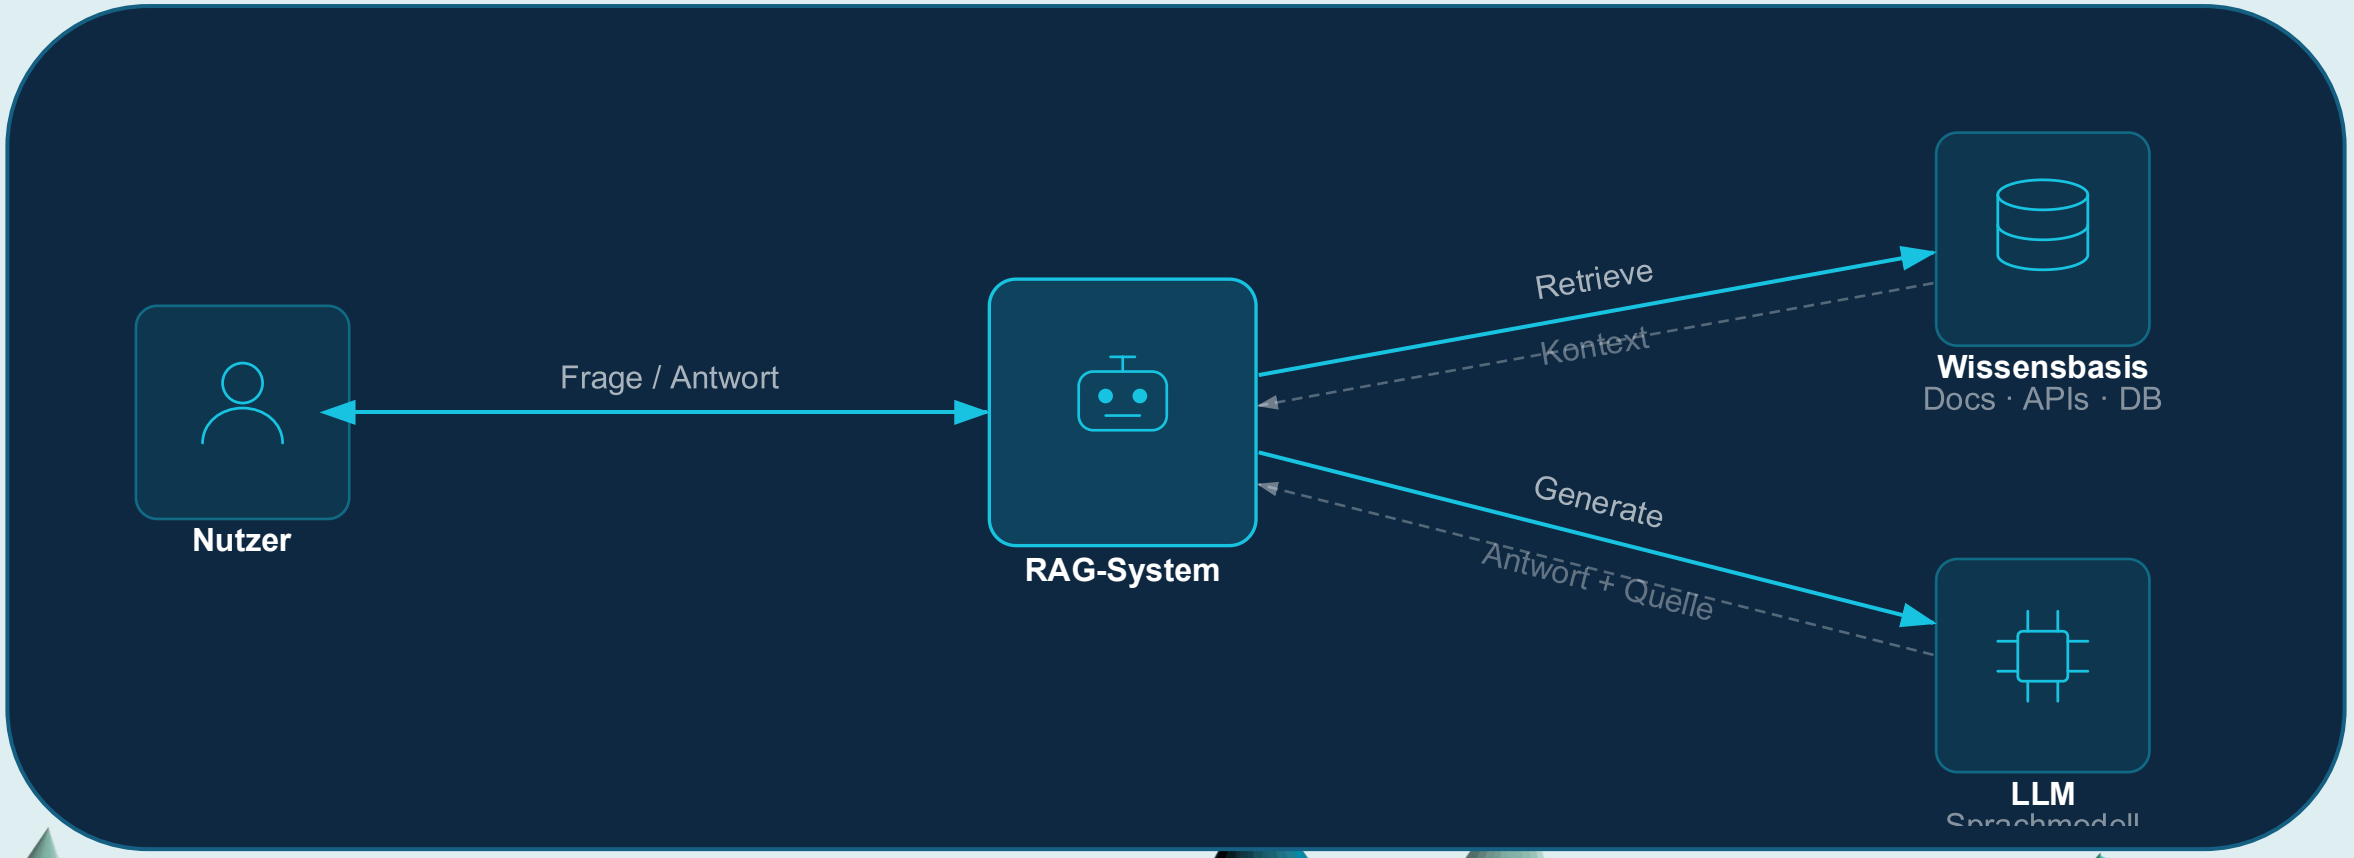

Entscheidend ist nicht der Prompt – sondern **was gefunden wird**

Chunking & Embeddings

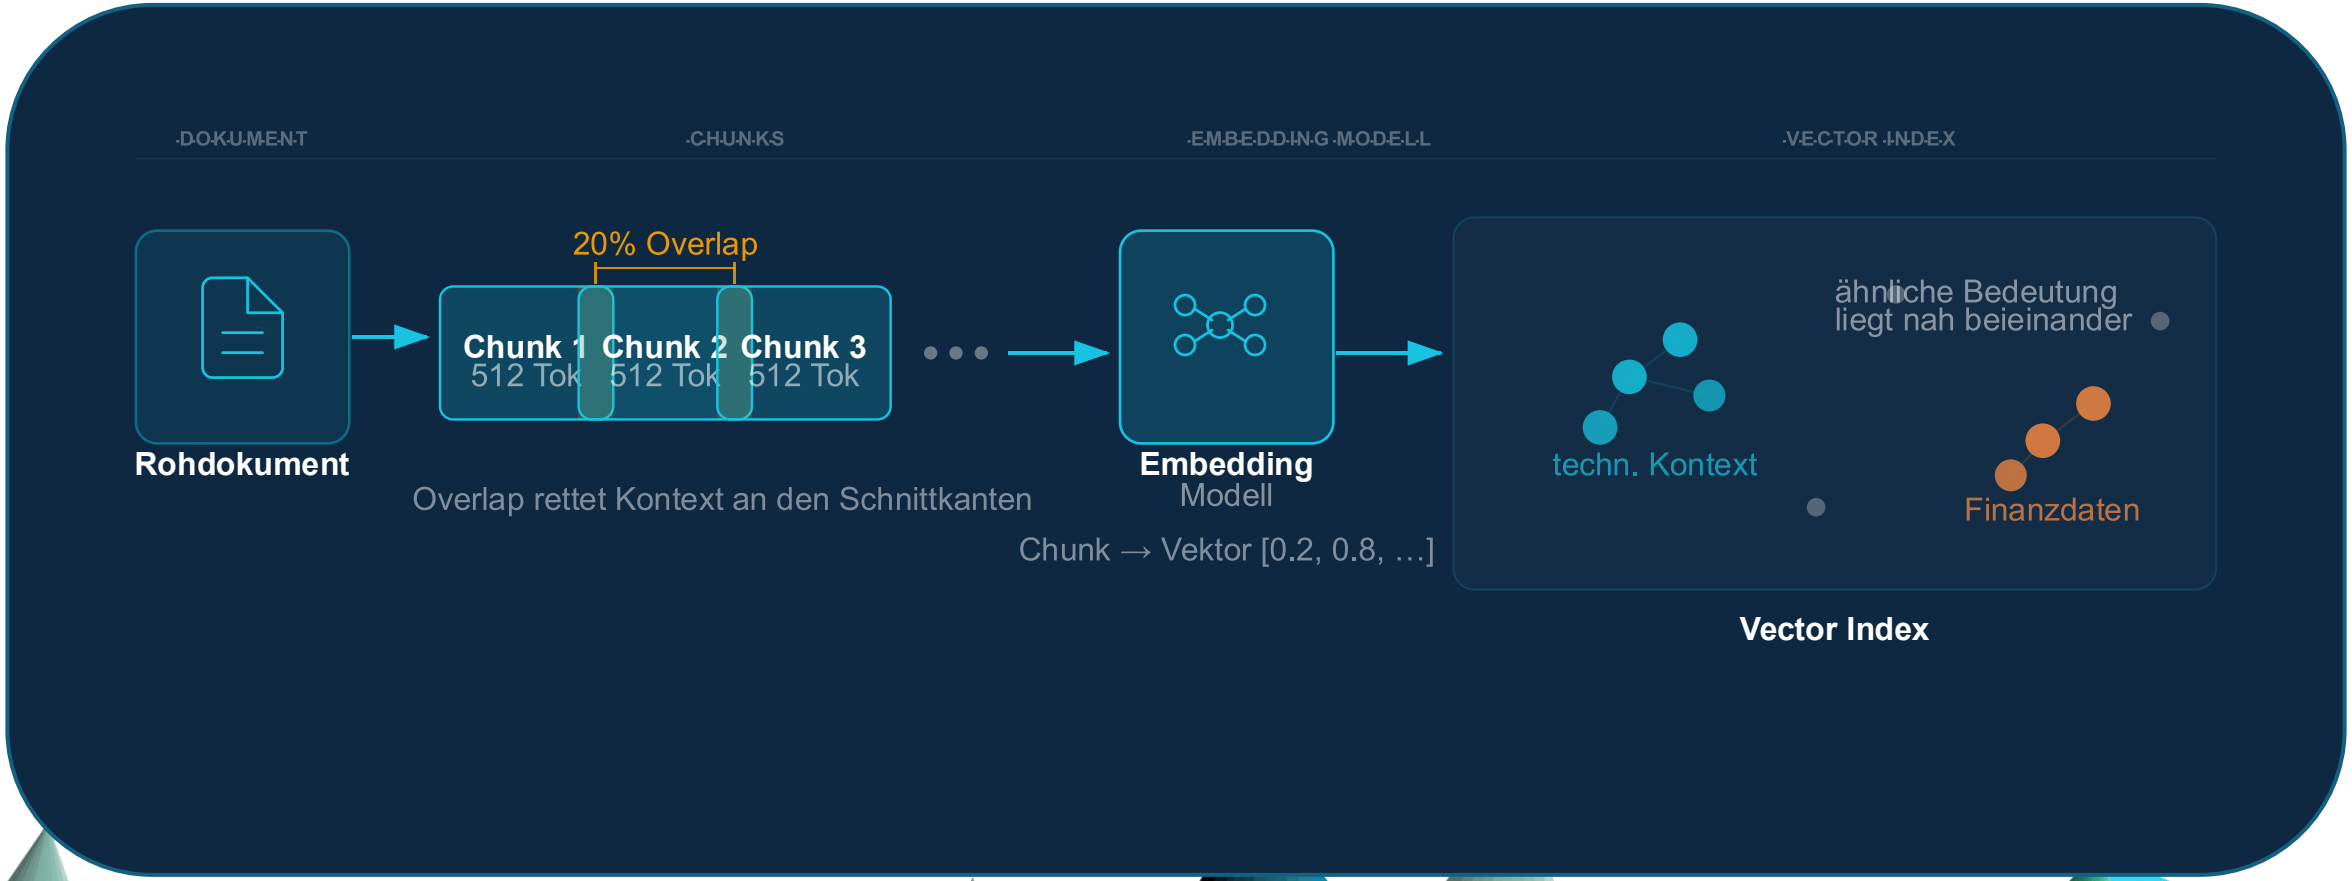

Der Hebel für Retrieval-Qualität sitzt im **Chunking** *– nicht im Prompt*

Agent & Tool-Calls

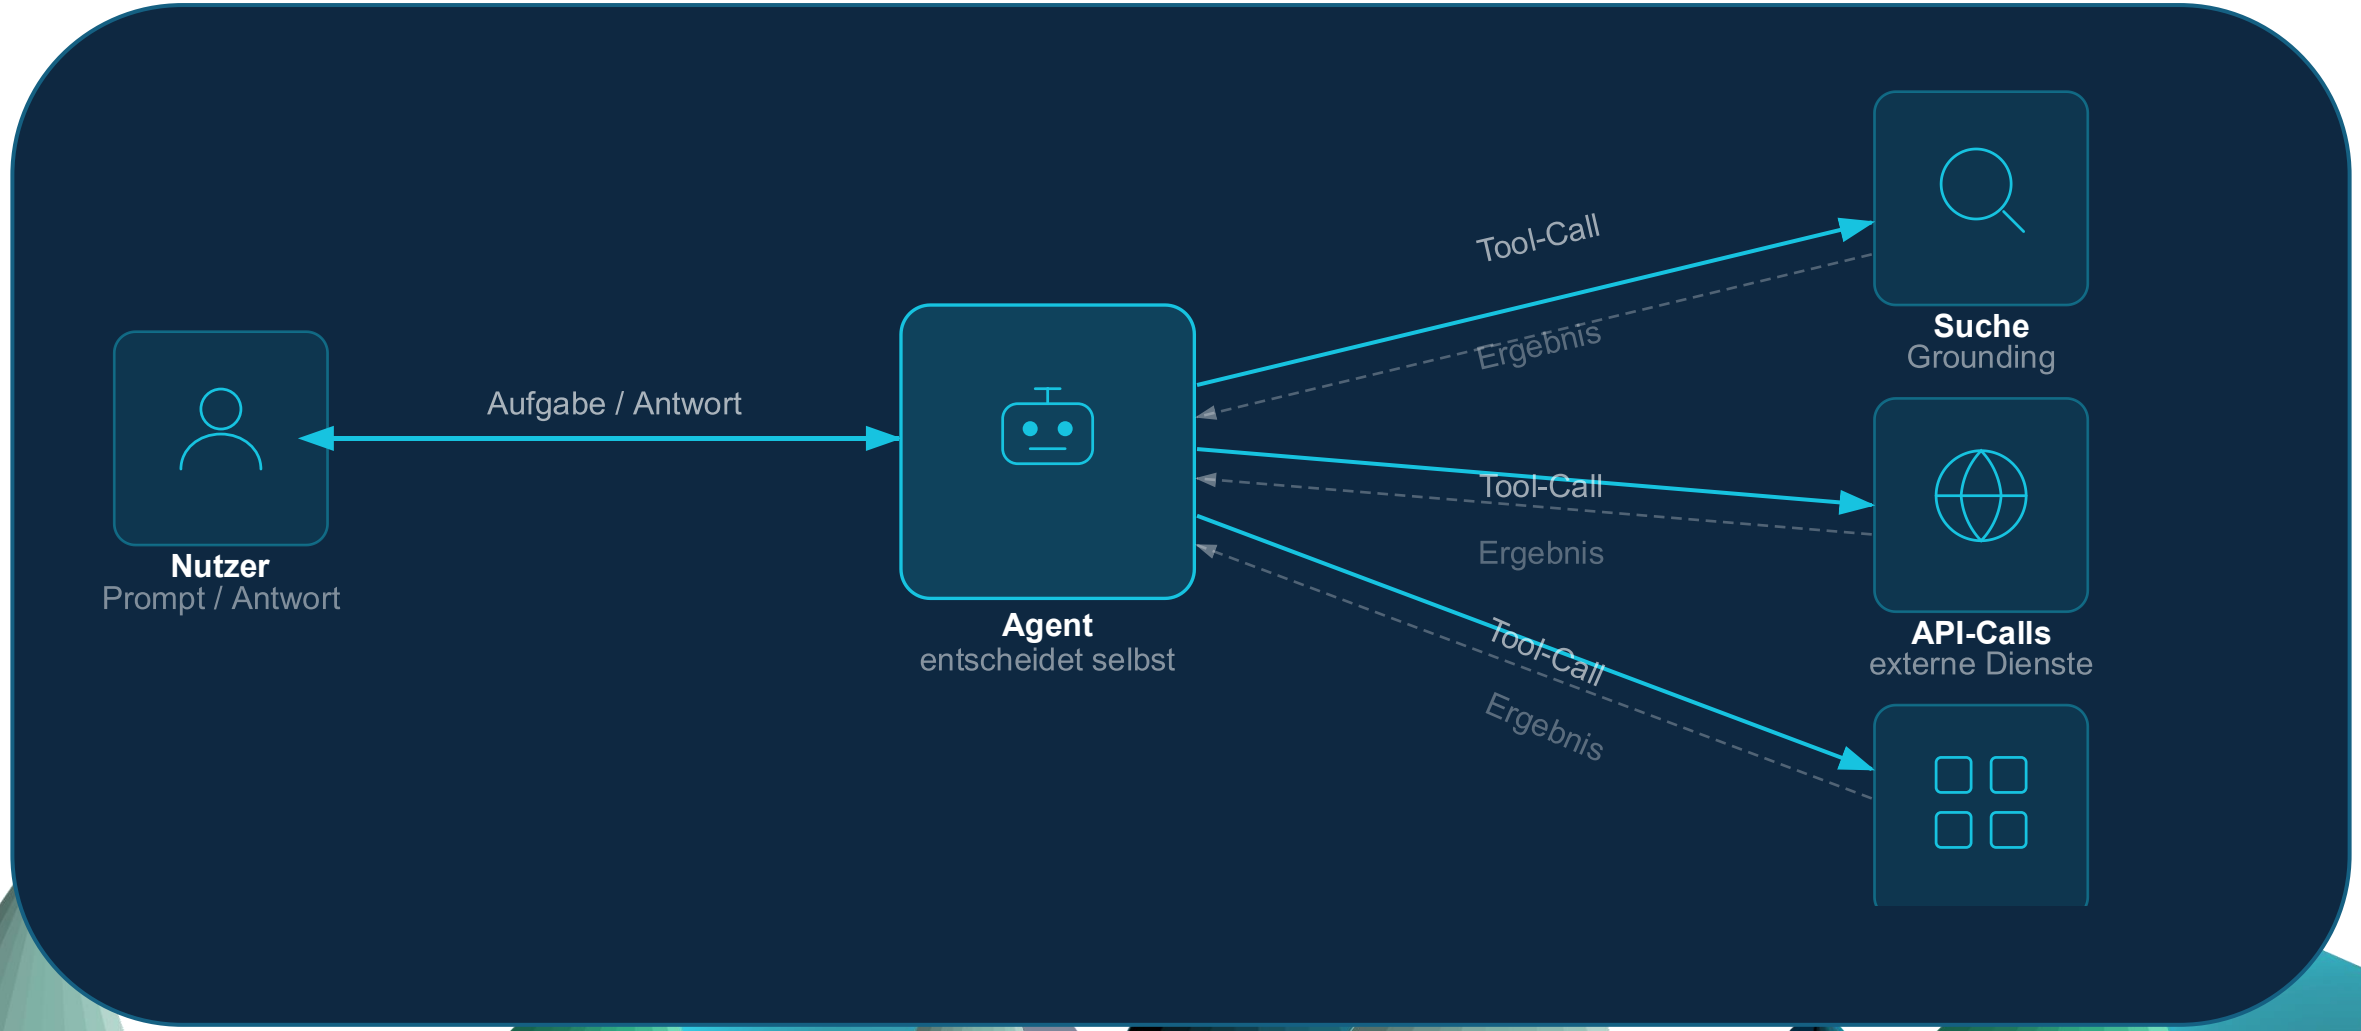

Orchestrierung in **Code** *– nicht im Klickmenü*

Tracing & Observability

OpenTelemetry

Infinity 365 Conference

Reinschauen statt raten – **Debugging und Kostenkontrolle** *in einem*

audiocodes AvePoint COSMO CONSULT CUBIC SOLUTIONS EXPERTS INSIDE neat. ppedv Rencore smartpoint bechtlegroup

Teil 2 · Die Praxis

Microsoft Foundry auf einer Folie

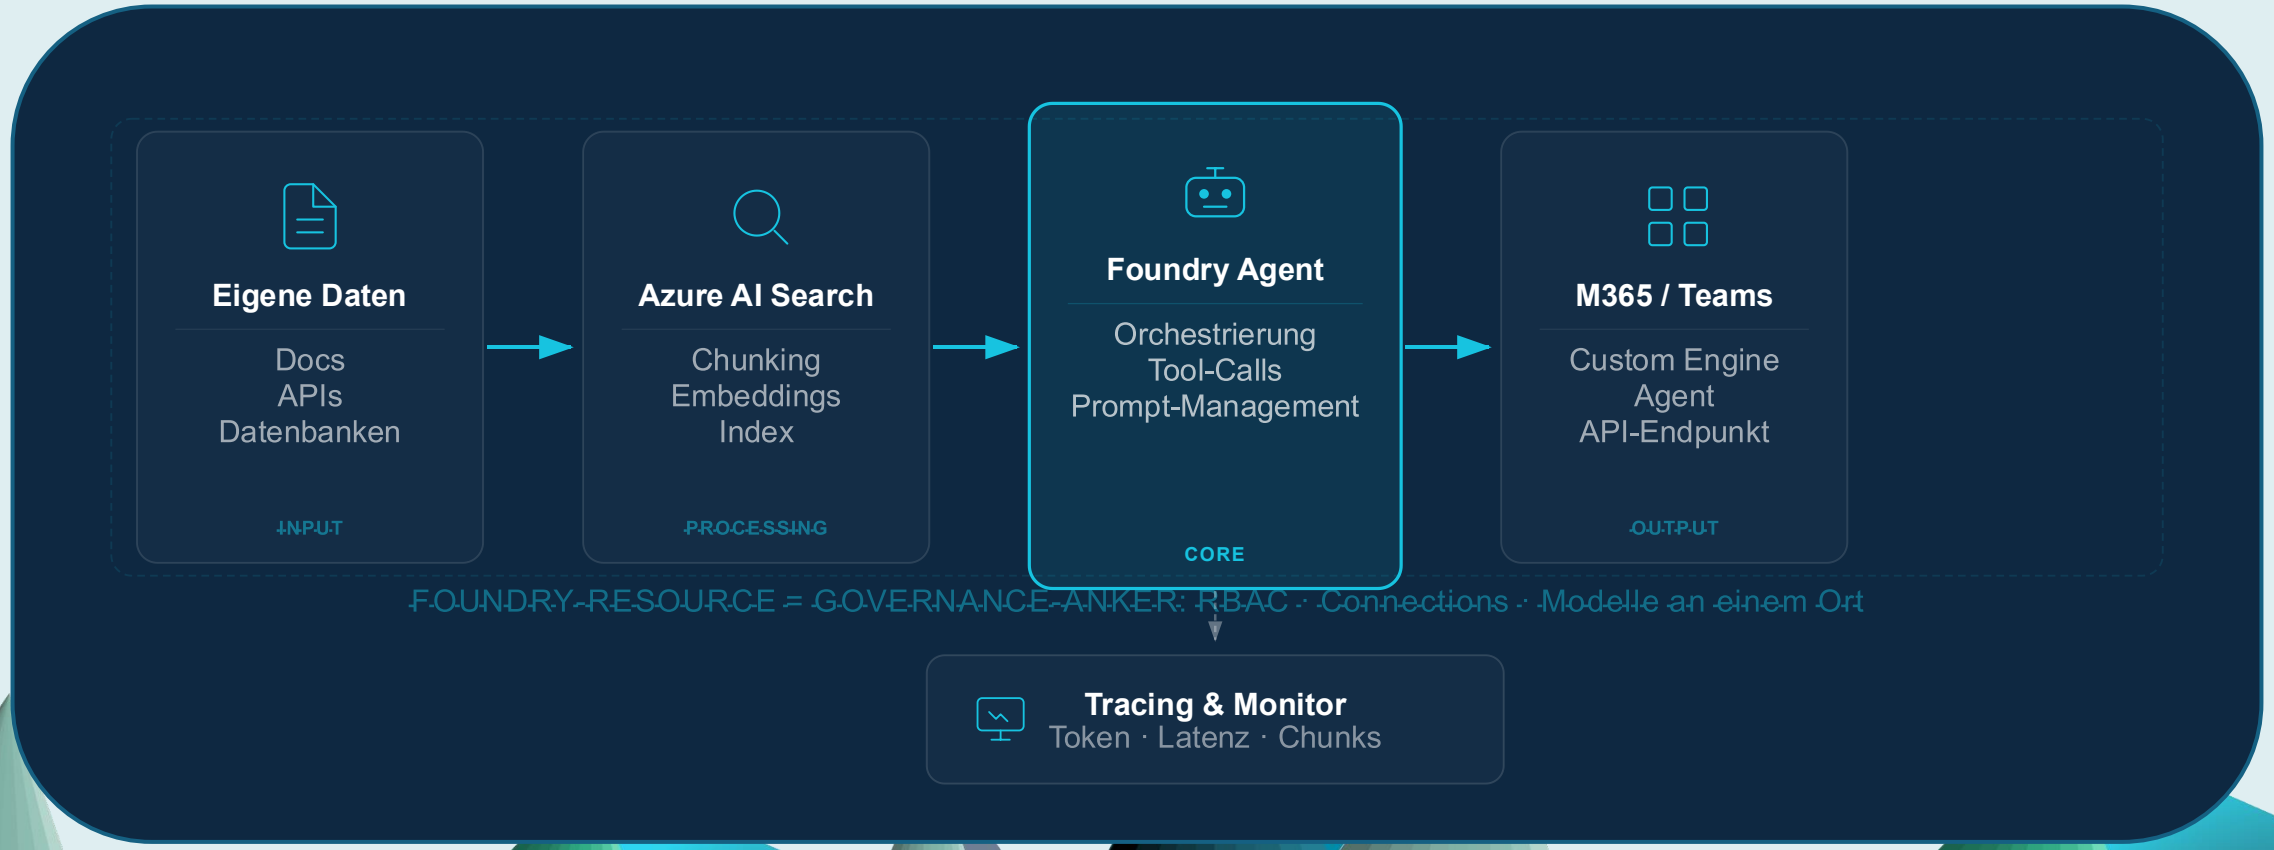

LIVE-DEMO · ~25 MIN · FRONTIER TENANT

Ein Wissens-Agent über interne Doku

1

Index aufbauen

- Chunking & Embedding
- reasoning, pre-deployed

→ Architekten

2

Agent im Code

- SDK, AI-Search-Tool
- Query, Tracing-Waterfall

→ Devs & Tech Leads

3

Brücke zu M365

- selber Agent,
- anderes Frontend

→ Alle

Eine Frage läuft durch alle drei Stufen — gleiche Antwort, anderes Frontend.

Die drei zentralen Fragen

Sicherheit

- RBAC auf Resource & Project
- Private Endpoints
- Managed Identity — keine Secrets

Kosten

- Token-Tracking pro Deployment
- Quotas & Monitoring
- Modellwahl = Preiseffekt

Qualität

- Foundry Evaluation
- Groundedness · Relevance
- Agent Optimizer

Takeaways

1

Volle Kontrolle = Feature, nicht Bug

- Foundry gibt Kontrolle zurück — auf Kosten von Komplexität.

2

RAG-Qualität entscheidet beim Index

- Chunking und Embedding sind die Hebel — nicht der Prompt.

3

Foundry + Copilot Studio = ein Stack

- Foundry als Backend, Copilot Studio als Frontend.

Fragen?

Vielen Dank!
Ich freue mich auf Feedback!

Scan mich!